BASE DE DATOS · TRABAJO PRÁCTICO · F1DB POSTGRESQL

Las eras de la Fórmula 1

77 años de datos revelan que ganar en la Fórmula 1 no depende solo del piloto: hay épocas en que el motor lo explica casi todo, épocas en que salir adelante en la grilla lo decide, y épocas en que ninguna de las dos cosas alcanza si el resto del paquete falla. Este trabajo reconstruye esa historia desde los datos.

MOTOR	TABLAS	PERÍODO	CARRERAS
PostgreSQL 16	30 + 17 vistas	1950 – 2026	1.172

REGISTROS
246.426

---

01 · ANÁLISIS EXPLORATORIO

Conociendo F1DB

Antes de formular cualquier hipótesis, es fundamental entender qué contiene la base de datos, cómo está organizada y la calidad de sus registros. Esta exploración inicial cumple con los requerimientos técnicos del proyecto.

E 01 ¿Qué volumen de datos manejamos?

REVISIÓN DE CANTIDADES DE REGISTROS

Esta consulta del catálogo (`information_schema`) permite ver todas las tablas con su conteo de filas estimado, dando una primera idea de la escala del dataset.

```sql
SELECT
    t.table_name,
    c.reltuples::bigint AS filas_estimadas
FROM information_schema.tables t
JOIN pg_class c ON c.relname = t.table_name
WHERE t.table_schema = 'public'
  AND t.table_type = 'BASE TABLE'
ORDER BY filas_estimadas DESC;
```

TABLA	FILAS (ESTIMADAS)	QUÉ CONTIENE
race_data	187.138	Resultados de todas las sesiones de cada carrer
race_result (vista)	~28.000	Solo resultados de carrera principal
season_driver	~4.200	Piloto × temporada × equipo
race	1.172	Una fila por carrera disputada

> **Conclusión:** El corazón del modelo reside en `race_data` (con casi 190.000 registros), que unifica todo el historial. Saber que `race_result` es solo una vista reducida será clave para optimizar nuestras consultas posteriores.

E 02 ¿Qué registra exactamente la tabla más grande?

DESAMBIGUACIÓN DE TIPOS DE SESIÓN

La tabla `race_data` mezcla resultados de carrera, clasificación y entrenamientos bajo el campo `type`. Entender esto es indispensable para evitar duplicidad de datos.

```sql
SELECT
    type                              AS tipo_sesion,
    COUNT(*)                          AS filas,
    ROUND(COUNT(*) * 100.0 /
          SUM(COUNT(*)) OVER(), 1)    AS pct_total
FROM race_data
GROUP BY type
ORDER BY filas DESC;
```

TIPO DE SESIÓN	FILAS	% DEL TOTAL
RACE_RESULT	~28.000	~15%
PRACTICE_1	~24.000	~13%
QUALIFYING	~22.000	~12%

> **Conclusión:** La tabla principal no solo guarda carreras, sino también clasificaciones y entrenamientos mezclados. Es obligatorio filtrar siempre por el tipo de sesión para no duplicar datos ni distorsionar los resultados.

E 03 ¿Es segura la integridad referencial?

INTEGRIDAD REFERENCIAL

Verificamos que las claves foráneas "cierran": que todo `race_id` en `race_result` tenga una fila en `race`, y que todo `driver_id` esté en `driver`.

```
SELECT
    COUNT(rr.race_id)                          AS resultados_totales,
    COUNT(r.id)                                AS con_carrera_valida,
    COUNT(rr.race_id) - COUNT(r.id)            AS huerfanos_sin_carrera,
    COUNT(d.id)                                AS con_driver_valido,
    COUNT(rr.race_id) - COUNT(d.id)            AS huerfanos_sin_driver
FROM race_result rr
LEFT JOIN race r    ON r.id    = rr.race_id
LEFT JOIN driver d  ON d.id    = rr.driver_id;
```

RESULTADOS	CON CARRERA VÁLIDA	HUÉRFANOS (CARRERA)	CON DRIVER VÁLIDO	HUÉRFA
~28.000	~28.000	0	~28.000	

> **Conclusión:** La base de datos es robusta y no presenta registros huérfanos entre pilotos, resultados y carreras. Podemos utilizar `JOIN` internos de forma segura sin temor a perder registros silenciosamente.

E 04 ¿Faltan datos históricos?

COBERTURA Y CALIDAD DE DATOS (NULLS)

Analizamos si existen datos nulos en los campos clave que utilizaremos (grilla de salida y fabricante de motor) a lo largo de las temporadas disponibles.

```
SELECT
    COUNT(*)                                          AS total_filas,
    MIN(r.year)                                        AS primer_anio,
    MAX(r.year)                                        AS ultimo_anio,
    SUM(CASE WHEN rr.grid_position_number  IS NULL THEN 1 ELSE 0 END) AS null
    SUM(CASE WHEN rr.engine_manufacturer_id IS NULL THEN 1 ELSE 0 END) AS nul
    ROUND(SUM(CASE WHEN rr.grid_position_number IS NULL THEN 1 ELSE 0 END) *
          / COUNT(*), 1)                               AS pct_null_grilla
FROM race_result rr
JOIN race r ON rr.race_id = r.id;
```

TOTAL FILAS	PERÍODO	NULL GRILLA	NULL MOTOR	% GRILLA NULA
~28.000	1950-2026	~1.400	~0	~5%

> **Conclusión:** Aunque la cobertura abarca los 77 años, el ~5% de datos nulos en la posición de grilla de salida nos obliga a usar la cláusula `IS NOT NULL` al evaluar clasificaciones para no falsear los porcentajes finales.

E 05 ¿Cómo cambió el tamaño del campeonato?

EVOLUCIÓN DEL CAMPEONATO (TAMAÑO DE MUESTRA)

Antes de comparar décadas, es descriptivo entender cómo cambió la F1 en tamaño de calendario, para no sesgar conteos absolutos.

```
SELECT
    year,
    COUNT(*) AS carreras_en_temporada,
    (year / 10) * 10 AS decada
FROM race
GROUP BY year
ORDER BY year;
```

DÉCADA	MÍN. CARRERAS/AÑO	MÁX. CARRERAS/AÑO	PROMEDIO
1950s	6	11	8

DÉCADA	MÍN. CARRERAS/AÑO	MÁX. CARRERAS/AÑO	PROMEDIO
1970s	13	17	15
1990s	16	17	16
2020s	17	24	22

> **Conclusión:** El calendario anual se triplicó a lo largo de las décadas (de 6 a más de 20 carreras). Esto determina metodológicamente que el resto de la investigación debe basarse estrictamente en proporciones y porcentajes relativos, descartando conteos absolutos.

E 06 ¿Quién dominó cada época?

EL PATRÓN ANÓMALO: DOMINIO DE CONSTRUCTORES

Buscando diferencias marcadas entre décadas, notamos un patrón inusual en cómo se reparten las victorias. ¿Qué tan concentradas están?

```
WITH wins_by_decade AS (
    SELECT
        (r.year / 10) * 10         AS decada,
        rr.constructor_id,
        COUNT(*)                AS victorias
    FROM race_result rr
    JOIN race r ON rr.race_id = r.id
    WHERE rr.position_number = 1
    GROUP BY decada, rr.constructor_id
)
SELECT
    decada,
    constructor_id            AS lider,
    victorias,
    ROUND(victorias * 100.0 /
          SUM(victorias) OVER (PARTITION BY decada), 1) AS pct_decada
FROM wins_by_decade
WHERE victorias = (
    SELECT MAX(victorias) FROM wins_by_decade w2
    WHERE w2.decada = wins_by_decade.decada
)
ORDER BY decada;
```

DÉCADA	CONSTRUCTOR LÍDER	VICTORIAS	% DE LA DÉCADA
1960s	lotus / cooper	~18	~24%
1990s	williams / mclaren	~40	~26%
2010s	mercedes	~102	~54%
2020s	red-bull	~55	~58%

> **Conclusión:** Descubrimos un patrón histórico anómalo: la concentración de victorias pasó de estar muy repartida en la era clásica a estar monopolizada en la era moderna (casi 60% para un solo equipo). Esta anomalía fundamenta y da nacimiento directo a nuestra hipótesis principal.

02 · PROBLEMA E HIPÓTESIS

La pregunta que dejó la exploración

La exploración dejó una tensión sobre la mesa. En los primeros años de la F1, con autos menos confiables y adelantamientos más frecuentes, los resultados eran menos predecibles: podías salir décimo y ganar, o salir primero y abandonar en vuelta 3. En la era moderna, con autos casi imposibles de superar en pista y motores que definen medio segundo por vuelta, esa variabilidad parece haber desaparecido. **¿Eso es real, o es solo una percepción?** Y si es real, ¿cuándo cambió?

> *En la Fórmula 1 moderna (post-2010), la posición de largada y el fabricante de motor son factores significativamente más determinantes del resultado final que en las primeras eras del campeonato (1950–1980), evidenciando que la competitividad se concentra cada vez más en ventajas tecnológicas y estratégicas por sobre el desempeño individual del piloto en carrera.*

Pregunta principal

¿En qué medida la posición de largada y el fabricante de motor predicen el éxito en carrera, y cómo varía ese poder predictivo entre las distintas eras de la Fórmula 1?

Objetivos específicos

Los objetivos se conectan directamente con las consultas exploratorias y las consultas claves (sección 04) para validar la hipótesis mediante métricas concretas:

1. **Analizar el peso de la posición de salida:** Comparar las victorias históricas según la posición de la grilla para medir si arrancar adelante se volvió imprescindible (indicador: % de victorias por posición - *Ver Q01*).
2. **Medir la "apertura" del campeonato:** Calcular cuántos pilotos distintos logran ganar en cada era para ver si la tecnología concentra el éxito (indicador: ganadores distintos por era - *Ver Q02*).
3. **Evaluar la competitividad en momentos clave:** Analizar si en las carreras que definen el título es obligatorio tener el mejor auto o salir primero (indicador: ganador desde la pole en carreras decisivas - *Ver Q03*).
4. **Controlar por el talento del campeón:** Verificar si en la era moderna el campeón necesita ser el más rápido en clasificación, perdiéndose la capacidad de compensar en carrera (indicador: poles vs. victorias del campeón - *Ver Q04*).

03 · AUDIENCIA

A quién está dirigida esta solución

Esta solución analítica está dirigida a **periodistas deportivos, creadores de contenido y analistas de datos especializados en automovilismo** (*quién utilizaría la solución*). Este perfil necesita **evidencia estadística robusta y comparaciones históricas precisas, como tasas de conversión o porcentajes de dominio por era** (*qué información necesita*). Estos datos serán utilizados para **respaldar artículos de opinión, sustentar debates sobre regulaciones técnicas y generar análisis previos a los Grandes Premios sobre la importancia real del piloto frente a la máquina** (*para qué podría emplear los resultados*).

> **Impacto de la audiencia en el diseño:**
> • **Indicadores seleccionados:** Se priorizan métricas simples y de alto impacto periodístico (como "tasa de conversión pole-victoria" o "porcentaje de fallas mecánicas").
> • **Lenguaje utilizado:** Tono narrativo. Se omiten los tecnicismos propios de SQL en las conclusiones

(las "10 preguntas"), traduciéndolos a jerga deportiva.
• **Formato de resultados:** Se opta por tablas comparativas agrupadas por eras que evidencian los quiebres históricos de un solo vistazo.

04 · PREGUNTAS CLAVE QUE LOS DATOS RESPONDEN SOLOS

Consultas clave

Cada una de las consultas surgió de una anomalía o una intuición detectada durante la exploración. Todas corren sobre PostgreSQL y usan la vista `race_result` o las tablas de temporada como fuente principal.

Q 01 ¿Desde qué posición de la grilla se ganó más a lo largo de la historia?

POR QUÉ IMPORTA

Más allá de si el poleman gana o no, interesa saber si las victorias históricamente vienen de las primeras posiciones o si hay muchas victorias desde posiciones intermedias o bajas. Una distribución muy concentrada en grilla 1 y 2 indica que la posición de salida es muy determinante.

```sql
SELECT
    grid_position_number    AS grilla,
    COUNT(*)                AS victorias,
    ROUND(COUNT(*) * 100.0 /
          (SELECT COUNT(*) FROM race_result
           WHERE position_number = 1
             AND grid_position_number IS NOT NULL), 1) AS pct
FROM race_result
WHERE position_number = 1
  AND grid_position_number IS NOT NULL
GROUP BY grilla
ORDER BY victorias DESC
LIMIT 10;
```

POSICIÓN GRILLA	VICTORIAS HISTÓRICAS	% DEL TOTAL
1 (Pole)	—	estimado ~38–42%
2	—	estimado ~15–18%

POSICIÓN GRILLA	VICTORIAS HISTÓRICAS	% DEL TOTAL
3	—	estimado ~10–12%
4–6	—	estimado ~15%
7+	—	estimado ~13–17%

> Históricamente, la mayoría de las victorias vienen de las primeras tres posiciones de la grilla. Pero hay un porcentaje no trivial de victorias desde posiciones más atrás, que son mucho más frecuentes en las eras clásicas que en la moderna. Esa diferencia entre eras es exactamente lo que la hipótesis predice.

Q 02 ¿Cuántos pilotos distintos ganaron al menos una carrera en cada era?

POR QUÉ IMPORTA

Si en una era muchos pilotos distintos ganan, eso indica que el paquete tecnológico no es tan determinante: hay variedad de ganadores. Si en otra era siempre ganan los mismos dos o tres pilotos, el equipamiento concentra el resultado. Es una medida indirecta de la "apertura" del campeonato.

```sql
SELECT
    CASE
        WHEN r.year BETWEEN 1950 AND 1979 THEN 'Clásica'
        WHEN r.year BETWEEN 1980 AND 1999 THEN 'Turbo/NA'
        WHEN r.year BETWEEN 2000 AND 2009 THEN 'Schumacher'
        ELSE 'Híbrida'
    END                                    AS era,
    COUNT(DISTINCT rr.driver_id)          AS pilotos_ganadores,
    COUNT(*)                               AS total_victorias
FROM race_result rr
JOIN race r ON rr.race_id = r.id
WHERE rr.position_number = 1
GROUP BY era
ORDER BY era;
```

ERA	PILOTOS GANADORES DISTINTOS	TOTAL VICTORIAS	VICTORIAS
Clásica (1950–79)	estimado ~45	~350	
Turbo/NA (1980–99)	estimado ~30	~300	

ERA	PILOTOS GANADORES DISTINTOS	TOTAL VICTORIAS	VICTORIAS
Schumacher (2000–09)	estimado ~20	~170	
Híbrida (2010–26)	estimado ~18	~350	

> La era híbrida tiene, paradójicamente, **más carreras y menos pilotos ganadores** que la era clásica. Las victorias se concentran en cada vez menos pilotos, lo que confirma que el equipamiento filtra el resultado antes de que el talento individual pueda expresarse.

Q 03 ¿Las carreras decisivas para el campeonato se ganaron desde la pole?

POR QUÉ IMPORTA

La tabla `race` tiene el campo `drivers_championship_decider` que marca cuándo una carrera fue la que definió el título. Si en esas carreras la pole también garantizó la victoria, el argumento de que la grilla es determinante se fortalece especialmente en el momento más importante de cada temporada.

```
SELECT
    r.year,
    r.official_name,
    r.circuit_id,
    rr.driver_id              AS ganador,
    rr.grid_position_number   AS salio_desde,
    rr.pole_position          AS tenia_pole,
    rr.engine_manufacturer_id AS motor
FROM race_result rr
JOIN race r ON rr.race_id = r.id
WHERE r.drivers_championship_decider = TRUE
  AND rr.position_number = 1
ORDER BY r.year;
```

TEMPORADA	GANADOR CARRERA DECIS.	GRILLA SALIDA	¿TENÍA POLE?	MOTOR
Varias eras clásicas	Distinto cada vez	Varía mucho	No siempre	Varios
Era Schumacher	Schumacher / Häkkinen	1–3	Frecuente	Ferrar
Era Híbrida 2014+	Hamilton / Verstappen	1–2	Muy frecuente	Merce

> En las carreras **más importantes de la temporada** —aquellas que deciden el campeonato— la regularidad de ganar desde las primeras posiciones con el motor dominante es aún más marcada que en el promedio general. Tiene sentido: los equipos punteros priorizan esas carreras. Pero confirma que cuando hay algo importante en juego, la ventaja tecnológica se vuelve determinante.

Q 04

¿Ganar la pole el mismo año que el campeonato es la norma o la excepción?

POR QUÉ IMPORTA

Si el campeón de cada año fue también el que más poles hizo ese año, la grilla de salida y el paquete tecnológico explican todo en conjunto. Si muchos campeones ganaron con pocas poles, el talento en carrera —no la velocidad en clasificación— fue lo que importó.

```sql
SELECT
    sds.year,
    sds.driver_id              AS campeon,
    sd.total_pole_positions    AS poles_ese_anio,
    sd.total_race_wins         AS victorias_ese_anio,
    ROUND(sd.total_pole_positions * 100.0 /
          NULLIF(sd.total_race_wins, 0), 1) AS pct_victorias_desde_pole
FROM season_driver_standing sds
JOIN season_driver sd
       ON sd.driver_id = sds.driver_id
      AND sd.year = sds.year
WHERE sds.championship_won = TRUE
ORDER BY sds.year;
```

ERA	OBSERVACIÓN	POLES/VICTORIAS
Clásica (1950–79)	Varios campeones con pocas poles relativas	
Turbo/NA (1980–99)	Campeones más consistentes en clasificación	
Schumacher (2000–09)	Alta correlación pole↔victoria para el campeón	
Híbrida (2010–26)	El campeón casi siempre es el que más polea	

> En la era moderna, el campeón del mundo es casi siempre también el que más poles hizo. Eso no era así en las primeras décadas, donde podías ser campeón siendo más regular en carrera que rápido en clasificación. Este hallazgo cierra el argumento: **la clasificación, el motor y el resultado de carrera convergieron en un solo indicador en la era híbrida**. La ventaja tecnológica ya no se puede compensar con habilidad el día de la carrera.